

Previsão de corridas de Green Taxi em Nova York utilizando XGBoost

João Henrique Ratto Martins


Introdução

- O objetivo é prever a quantidade de corrida de green táxis por hora na cidade de Nova York no ano de 2023 utilizando dados das corridas e agregando informações climáticas.
- Green taxis são utilizados na periferia, onde a demanda é menor.
 - A maioria dos trabalhos encontrados utilizavam yellow taxis, por isto este dataset foi selecionado.
- Objetivo dividido em dois algoritmos principais:
 - Tratamento do dataset,
 - Treinamento do modelo de predição.
- A Venue escolhida é a BreSci, por se tratar de análise de dados abertos e Humanidades e Ciências sociais.

Hipótese

- Adicionar um volume maior de informações sobre clima do que sobre as corridas, pode gerar bons resultados?

Feature importance




Tratamento dos datasets - Entrada de datasets

- Treinamento do imputer
 - ClimaTreino.csv
- Treinamento do modelo de predição
 - Clima2022.csv
 - 2022_Green_Taxi_Trip_Data_20260530.csv
- Teste do modelo de predição
 - Clima2023.csv
 - 2023_Green_Taxi_Trip_Data_20260519.csv

Tratamento dos datasets - Fluxograma


- Imputer é treinado para preencher nulos dos datasets meteorológicos.
- O tratamento dos dados do taxi é realizado retirando linhas com dados incoerentes, como:
 - Corridas sem passageiros,
 - Corridas com distâncias maiores que a cidade.



Predição


- Utilizado o XGBoost, pois como demonstrado em em alguns trabalhos, este modelo pode apresentar bons resultados.
- Dados agrupado por hora.
- Tamanho dos datasets:
 - Treino com 8758,
 - Teste com 7985.
- Otimização de hiperparâmetros
 - Empiricamente,
 - Otimização Bayesiana,
 - Grid Search.

Predição - Fluxograma do treino e teste




Análise de Variáveis


- Variáveis meteorológicas fizeram diferença para o modelo.
- Os horários possuem muita influência, pois gera picos de demanda.



Análise do dataset




Análise do dataset




Resultados

- O modelo acompanha o comportamento real.
- Possui sensibilidade a movimentos de alta.




Resultados

- A partir do ponto (150, 150) o sistema tende ao erro.
- O modelo não soube lidar com volume de corrida próximo a zero.




Resultados



Resultados

Comparação do Volume Total de Corridas: Real vs. Previsto por Mês



Performance

- Comparação com base em R^2
 - Empírico: 87,90%
 - Uttunga et al.: 73%
- Comparação com base em RMSE
 - Empírico: 17,57
 - Poongodi et al.: 0,39

Otimização do Modelo			
Hiperparâmetros	Empírico	BayesianOptimization	GridSearch
n_estimators	550	492	700
learning_rate	0.005	0.00802122778072089	0.01
max_depth	8	6	6
subsample	0.3	0.772640650610975	0.2
min_child_weight	5	15	7
num_parallel_tree	1	11	4
Indicadores de Performance			
MAE	12.16	12.30	12.49
R^2	87.90%	87.26%	86.97%
MSE	308.80	324.92	332.38
RMSE	17.57	18.03	18.23

Limitações

- O tratamento reduziu muito a quantidade de amostras.
- O deslocamento urbano pode ser alterado por eventos não mapeados.
- A inclusão de mais features do dataset de táxis pode melhorar o resultado.

Conclusão

- O modelo possui espaço para melhoria.
- Os dados meteorológicos fizeram diferença.
- É necessário melhorar o comportamento da predição em horário de pico.
- A adição de mais variáveis relacionadas às corridas de taxi pode auxiliar na predição.
- Em trabalhos futuros deve-se aumentar a quantidade de amostras de treino.

Obrigado!