

Previsão de corridas de Green Taxi em Nova York utilizando XGBoost

João Henrique Ratto Martins¹

¹Departamento Acadêmico de Computação
Universidade Tecnológica Federal do Paraná (UTFPR) Campo Mourão – PR – Brazil

jhratto@gmail.com

Abstract. *The efficiency of urban mobility in metropolitan areas is a constant technological challenge, in which urban mobility services generate massive volumes of data every day. As the demand for transportation does not follow a linear behavior and is sensitive to external factors, such as weather variations, predicting this demand is essential to mitigate operational inefficiencies, such as fleet idleness or long passenger waiting times. This work proposes a predictive model for the hourly ride volume of the Green Taxi fleet in New York City using the Extreme Gradient Boosting (XGBoost) algorithm. For the prediction, ride datasets from 2022 were used for training and data from 2023 for testing, grouped and merged with weather data that were previously processed using the IterativeImputer method. Hyperparameter tuning was evaluated using three approaches: empirical tuning, Bayesian Optimization, and Grid Search. The empirically tuned model achieved the best performance, reaching an R^2 coefficient of 87,90% and a Mean Absolute Error (MAE) of 12,16 rides. Feature importance analysis indicated that variables such as hour of the day, temperature, month, and humidity have the greatest influence on the algorithm's decision-making process.*

Resumo. *A eficiência da mobilidade urbana em grandes centros é um desafio tecnológico constante, cenário no qual os serviços de mobilidade urbana geram volumes massivos de dados diários. Como a procura por transporte não possui comportamento linear e é sensível a fatores externos, como variações meteorológicas, prever essa demanda é essencial para mitigar ineficiências operacionais, como a ociosidade da frota ou a longa espera de passageiros. Este trabalho propõe um modelo preditivo para o volume horário de corridas da frota Green Taxi na cidade de Nova York, utilizando o algoritmo Extreme Gradient Boosting (XGBoost). Para a realização da previsão, foram aplicados datasets de corridas dos anos de 2022 para treinamento e 2023 para teste, agrupados e unificados a dados climáticos tratados preliminarmente através do método IterativeImputer. O ajuste de hiperparâmetros foi avaliado sob três abordagens: empiricamente, via Otimização Bayesiana e via GridSearch. O modelo com ajuste empírico obteve o melhor desempenho, alcançando um coeficiente R^2 de 87,90% e um Erro Absoluto Médio (MAE) de 12,16 corridas. A análise de importância das features indicou que variáveis como a hora do dia, temperatura, mês e umidade possuem o maior peso na tomada de decisão do algoritmo.*

1. Introdução

O rápido crescimento dos grandes centros, colocaram a eficiência da mobilidade urbana no foco das prioridades tecnológicas, abrindo espaço para empresas como a Uber. Neste cenário, os serviços de transporte, como táxis, desempenham um papel importante na dinâmica de deslocamento das cidades. Diariamente, estes serviços geram volumes massivos de dados, criando um volume de informação propício à aplicação de técnicas de Inteligência Artificial.

A procura por transporte urbano não possui comportamento linear. A quantidade de viagens requisitadas num determinado intervalo de tempo é sensível a diversos fatores externos como variação meteorológica, e a dificuldade em mapear esta complexidade pode resultar em desequilíbrios entre a oferta e a procura, gerando ineficiências operacionais, como o aumento do tempo de ociosidade das veículos ou períodos de longa espera para os passageiros.

Para mitigar estas ineficiências, será proposto uma análise utilizando dados reais de corridas de táxi e variações climáticas, com o objetivo de prever com precisão o volume de corridas utilizando Extreme Gradient Boosting.

2. Trabalhos Relacionados

Na predição de tempo de viagem de táxis em Nova York, [Poongodi et al. 2022] avaliaram o algoritmo XGBoost por meio da métrica de Raiz do Erro Quadrático Médio (RMSE), obtendo um valor de 0,39 na base de treinamento e 0,44 na base de teste após 250 iterações. Em comparação, o modelo concorrente Multi-Layer Perceptron (MLP) obteve uma acurácia de teste de aproximadamente 0,41, o que levou os autores a concluir pela ligeira superioridade e maior confiabilidade do XGBoost.

Explorando também a predição de tempo de viagem em Nova York, [KR et al. 2024] propuseram um modelo híbrido denominado DyGCN-LSTM e utilizaram o XGBoost como método de extração de importância de features. O modelo proposto pelos autores obteve boa precisão, aplicando-se ao dataset de 2022, o sistema apresentou um RMSE de apenas 5,22 e um Erro Absoluto Médio (MAE) de 1,65. A precisão do modelo foi de 0,953 e o F1-score alcançou 0,901, indicando uma forte capacidade de generalização e baixo desvio preditivo.

Ainda realizando predição, [Uttunga et al. 2025] avaliaram múltiplos regressores para a cidade de Nova York. O modelo XGBoost apresentou um coeficiente de determinação R^2 de 73% e um Erro Percentual Absoluto Médio (MAPE) de 35,62%. O algoritmo apresentou ainda um RMSE de 26,42 e um MAE de 19,17. Neste mesmo estudo, o modelo Random Forest apresentou resultados ligeiramente superiores em algumas métricas, atingindo um R^2 de 83% e um RMSE de 25,95, consolidando as técnicas baseadas em árvores como estáveis e com baixo desvio médio para predição deste tipo de dataset.

No estudo realizado por [Vanichrujee et al. 2017], os autores utilizaram a métrica sMAPE (Symmetric Mean Absolute Percentage Error) para aferir o desempenho preditivo dos algoritmos. O modelo XGBoost obteve excelentes desempenhos em áreas de alto fluxo, registrando um erro sMAPE de apenas 17,31% em aeroportos, 24,10% em atrações turísticas e 24,21% em lojas de departamento. O modelo ensemble proposto pelos autores

(que combina XGBoost, LSTM e GRU) atingiu um erro sMAPE médio geral de 24,02% em todas as áreas avaliadas, superando o desempenho dos modelos independentes na média consolidada.

3. Dados e Definição do Problema

Para realizar as previsões, foram selecionados dados de Green Taxi, que atuam na cidade de Nova York, EUA. Diferentemente dos Yellow taxis, os Green Taxis não podem atuar no centro da cidade, somente zonas periféricas como Brooklyn, Queens, Bronx, Staten Island e no norte de Manhattan, acima da Rua 110 no lado oeste e da Rua 96 no lado leste. O Green Taxis foram colocados em circulação em locais com pouca demanda de taxis para facilitar o deslocamento nestes bairros. Apesar de serem proibidos de iniciar a corrida na região central, o passageiro pode encerrar a corrida em qualquer ponto da cidade. A tarifa das duas modalidades é a mesma. [Green Cabs 2026]

Foi selecionada esta categoria de taxi, pois existem poucos trabalhos realizando sua análise, a maioria dos trabalhos analisados utilizam Yellow Taxi. Foram selecionados dois datasets distintos para treino e teste, um com informações do ano de 2022 nomeado como [New York City Taxi and Limousine Commission (TLC) 2023] e outro com informações do ano 2023 nomeado como [New York City Taxi and Limousine Commission (TLC) 2024] . O dataset de 2022 será utilizado para treinar o modelo de previsão, que será aplicada no dataset de 2023.

Também foi utilizado dados do clima de Nova York, coletados do banco de dados da Universidade Estadual de Iowa: [Iowa Environmental Mesonet (IEM) 2026]. Foram selecionados os seguintes dados:

- Stations: NYC;
- Timezone of Observation Times: America/New_York (EST/EDT);
- Available Data:
 - Air Temperature;
 - Relative Humidity;
 - Wind Direction;
 - Wind Speed [mph];
 - 1 hour Precipitation [mm].

Foram selecionados três datasets com os dados indicados acima, alterando somente o ano da coleta. O dataset de nome treinamentoClima será utilizado para realizar o treinamento do imputer para preencher valores nulos dos outros datasets de clima e possui dados dos anos 2017, 2018, 2019, 2020 e 2021. O dataset de nome Clima2022 será utilizado para treinar o modelo de previsão e possui dados do ano de 2022. Já o dataset de nomeado como Clima, será utilizado para teste do modelo de previsão e possui dados do ano de 2023.

4. Metodologia

Para separar os processos e facilitar o fluxo de treinamento do modelo de previsão, foi desenvolvido dois algoritmos, um com o objetivo de treinar o imputer e unir os dados de clima e taxi, o outro algoritmo possui o objetivo de treinar o modelo de previsão com os dados de saída do algoritmo anterior, realizar métricas de análise de erro e plotar os gráficos com os resultados.

O algoritmo "Tratamento.ipynb" deve ser o primeiro a ser executado, seu fluxo é demonstrado na Figura 1, as elipses indicam os datasets de entrada ou saída e os retângulos indicam os processos do algoritmo. Como entrada, temos os datasets "treinamentoClima", "taxi_2023", "Clima", "taxiTreino" e "Clima2022". O dataset "treinamentoClima" é utilizado para realizar o treinamento do imputer que realizará o preenchimento dos valores nulos encontrados nos datasets "Clima" e "Clima2022". Com os valores preenchidos, os datasets com dados de mesmo ano são unificados, "taxi_2023" é agrupado com "Clima", adicionado uma coluna que indica quando a data da corrida acontece em um final de semana ou feriado de 2023, assim, temos como saída o dataset "taxi_clima". O mesmo processo de agrupamento acontece com os datasets "taxiTreino" e "Clima2022", onde também é adicionado uma coluna indicando se a corrida aconteceu em um feriado ou final de semana de 2022. O resultado deste processo é o dataset "taxiTreino_clima".




Figura 1. Fluxograma de treinamento do Iterative Imputer

Com os datasets "taxi_clima" e "taxiTreino_clima" é possível realizar o treinamento do modelo executando o algoritmo "TreinamentoModelo.ipynb", seu fluxo é demonstrado na Figura 2. Onde cada um dos datasets citados serão agrupados por hora, recebe três variáveis, sendo hora, dia da semana e mês. Após este processo o dataset "taxiTreino_clima" é utilizado para treinar o algoritmo de predição e o teste é realizado no dataset "taxi_clima".




Figura 2. Fluxograma de treinamento do modelo de previsão

5. Configuração experimental

5.1. Tratamento dos Datasets

O primeiro algoritmo a ser executado deve ser o "Tratamento.ipynb", e recebe cinco datasets. O dataset "treinamentoClima" possui dados meteorológicos dos anos 2017, 2018, 2019, 2020 e 2021, este volume de dados se justifica pois irá realizar o treinamento do imputer. O dataset "Clima" possui dados meteorológicos do ano de 2023 e será utilizado para teste do modelo de previsão. O dataset "Clima2022" será utilizado para treinar o modelo de previsão e possui dados meteorológicos de 2022. O dataset "taxiTreino" será utilizado para treinar o modelo de previsão e possui dados de corridas de taxi de 2022. O dataset "taxi_2023" possui dados de corridas de taxi de 2023 e será utilizado para testar o modelo de previsão.

Os três datasets com dados meteorológicos receberam alterações em algumas de suas colunas para facilitar sua compreensão, as colunas alteradas foram indicadas na Tabela 1. Os valores indicados no dataset como vazio, espaço simples, 'N/A', 'T' e 'M' foram preenchidos como nulo. As corridas foram ordenadas de forma crescente em relação à data e a contagem das linhas foi refeita.

No tratamento dos dataset de taxis, foram apagadas linhas onde trip_distance ou quantidade de passageiros é zero ou NaN. Também foi apagado a linha quando a coluna trip_distance for maior que 700 [milhas], pois é uma distância muito grande para se transitar em uma cidade. Em seguida as linhas foram ordenadas de forma crescente em relação a data e a contagem das linhas foi refeita. Este tratamento foi realizado pois podem ser dados inseridos de forma errada no sistema e pode interferir na previsão.

Este modelo foi aplicado somente nos datasets com dados meteorológicos. Não foi realizado método de imputação nos datasets com dados de corridas de taxi pois o tratamento realizado elimina os dados vazios e discrepantes.

Tabela 1. Colunas Renomeadas

Colunas Renomeadas	
Nome Original	Novo Nome
valid	data
tmpc	temperatura [C°]
relh	umidade relativa [%]
drct	direção do vento [°]
sped	velocidade do vento [mph]
p01m	precipitação acumulada em 1 hora [mm]

O modelo de imputação utilizado foi o `IterativeImputer` da biblioteca `scikit-learn`, com os seguintes hiperparâmetros: `random_state=85`, `max_iter=80` e `initial_strategy='mean'`. O treinamento foi realizado com o dataset "treinamentoClima" e aplicado nos datasets "Clima2022" e "Clima".

Foi realizado o agrupamento dos datasets com dados meteorológicos e de corridas de taxi, este processo agrupa os datasets "taxi_2023" com "Clima" e "taxiTreino" com "Clima2022" como indicado na Figura 1. Foi utilizando como referência a data e hora dos dois conjuntos de dados de forma que a data da corrida seja maior que a data do clima, esta comparação é realizada em cada linha do dataset de corridas de taxi, e recebe as seguintes colunas: temperatura [C°], umidade relativa [%], direção do vento [°], velocidade do vento [mph] e precipitação acumulada em 1 hora [mm]. Ao final do processo, foi adicionado a coluna feriado/fim de semana, que recebe valor 1 para dias que são feriado ou final de semana e 0 para outros dias. O conjunto de dados com os feriados e finais de semana foi gerado com base na biblioteca `holidays`, os feriados de 2022 foi salvo em `datas_especiais_2022` e o dado de 2023 foi salvo em `datas_especiais_2023`. A agrupamento dos datasets "taxi_2023" e "Clima" gera "taxi_clima" e o agrupamento de "taxiTreino" com "Clima2022" gera o dataset "taxiTreino_clima".

5.2. Treinamento do Modelo de Predição

O treinamento do modelo de predição é realizado no algoritmo "TreinamentoModelo.ipynb" e recebe como entrada os datasets "taxi_clima" e "taxiTreino_clima". Para que o treinamento e a predição se tornem possíveis, é realizado o agrupamento dos dados destes dois datasets por hora. Também é gerado as colunas "hora_do_dia", "dia_da_semana" e "mes", para que ainda existam dados temporais para auxiliar na predição. Após este tratamento o dataset "taxiTreino_clima" recebe o nome "treino_agg" e o dataset "taxi_clima" tem seu nome alterado para "teste_agg".

O modelo de predição escolhido foi o `XGBoost`, pois, como foi demonstrado por [Uttunga et al. 2025], modelos baseados em árvores podem apresentar bons resultados em datasets similares ao utilizado neste trabalho. A seleção de hiperparâmetros foi realizada de três formas, empiricamente, aplicando Otimização Bayesiana e aplicando Grid-Search. O hiperparâmetro "random_state" foi mantido com o valor 15 sempre que foi possível utilizá-lo, para manter a repetibilidade. O ajuste empírico foi o primeiro a ser realizado. Foram testados os parâmetros "n_estimators", "learning_rate", "max_depth", "subsample", "min_child_weight", "colsample_bynode", "colsample_bytree", "colsample_bylevel", "num_parallel_tree", "tree_method", "max_delta_step", "gamma",

"reg_alpha", "reg_lambda". Dentre estes, poucos surtiram efeito de diminuição do erro, a maioria dos citados aumentou o erro do modelo. Os parâmetros que responderam melhor a esta aplicação foram "n_estimators", "learning_rate", "max_depth", "subsample", "min_child_weight", "num_parallel_tree".

As *features* para a Otimização Bayesiana e para o GridSearch foram as mesmas, sendo elas: "temperatura", "umidade", "precipitacao", "vento_vel", "feriado_fds", "hora_do_dia", "dia_da_semana" e "mes". Na Otimização Bayesiana, foram utilizados os seguintes parâmetros de busca:

```
# Espaço de Busca Bayesiano
param_bayes = {
    'n_estimators': Integer(200, 1000),
    'max_depth': Integer(4, 9),
    'min_child_weight': Integer(1, 15),
    'subsample': Real(0.1, 1.0),
    'num_parallel_tree': Integer(1, 15),
    'learning_rate': Real(0.001, 0.1, prior='log-uniform')
}
```

Estes valores para a busca foram selecionados para englobar os valores encontrados na forma empírica, que pode ser observado na Tabela 2, a seleção destes valores foi realizada para evitar *overfit*. A configuração do modelo bayesiano foi realizado da seguinte forma:

```
# Configuração da Otimização Bayesiana
busca_bayesiana = BayesSearchCV(
    estimator=modelo_base,
    search_spaces=param_bayes,
    n_iter=50,
    scoring='neg_mean_absolute_error',
    cv=5,
    n_jobs=-1,
    random_state=15,
    verbose=3
)
```

Os parâmetros abaixo foram utilizados para a busca do GridSearch e foram selecionados para estarem próximos aos selecionados empiricamente e para se aproximarem da Otimização Bayesiana e manter a similaridade entre as duas otimizações.

```
# Espaço de busca do GridSearch
param_grid = {
    'n_estimators': [400, 550, 700],
    'max_depth': [4, 6, 8],
    'subsample': [0.2, 0.3, 0.5],
    'min_child_weight': [3, 5, 7],
    'num_parallel_tree': [1, 2, 4],
    'learning_rate': [0.001, 0.01, 0.1]
}
```

Abaixo segue a configuração do GridSearch. O parâmetro *scoring* foi selecionado para que o resultado tenha a menor média de erro. O parâmetro *cv* ou *Cross-Validation* foi selecionado para evitar *overfit* e para retornar parâmetros com erro mais baixo possível.

```
# Configuração do grid search
grid_search = GridSearchCV(
    estimator=modelo_base,
    param_grid=param_grid,
    scoring='neg_mean_absolute_error',
    cv=3,
    n_jobs=-1,
    verbose=3
)
```

A tabela 2 indica quais são os hiperparâmetros testados e seus indicadores de performance. Como é possível notar, o melhor resultado é do ajuste empírico, estes serão os hiperparâmetros utilizados.

Tabela 2. Hiperparâmetros do Modelo de Predição

Otimização do Modelo			
Hiperparâmetros	Empírico	BayesianOptimization	GridSearch
n_estimators	550	492	700
learning_rate	0.005	0.00802122778072089	0.01
max_depth	8	6	6
subsample	0.3	0.772640650610975	0.2
min_child_weight	5	15	7
num_parallel_tree	1	11	4
Indicadores de Performance			
MAE	12.16	12.30	12.49
R^2	87.90%	87.26%	86.97%
MSE	308.80	324.92	332.38
RMSE	17.57	18.03	18.23

O dataset "taxiTreino.clima" foi utilizado para treinar o modelo e o dataset "taxi.clima" foi utilizado para teste. As *features* utilizadas para treinar o modelo foram "temperatura", "umidade", "precipitacao", "vento_vel", "feriado_fds", "hora_do_dia", "dia_da_semana" e "mes".

6. Resultados e Discussão

Para avaliar a eficácia do modelo XGBoost ajustado empiricamente, os resultados foram analisados sob múltiplas perspectivas, incluindo a distribuição temporal da demanda, a dispersão dos erros, a importância das features e o comportamento preditivo em janelas de tempo específicas. A otimização empírica apresentou os melhores indicadores de performance, atingindo um coeficiente de determinação R^2 de 87,90% e um Erro Absoluto Médio (MAE) de 12,16 corridas.

O comportamento do dataset de teste pode ser verificado na Figura 3. Neste gráfico pode-se observar que o maior volume de corridas se inicia 15 horas e diminui

a partir das 19 horas. Este intervalo de pico coincide com a transição do horário comercial para o período noturno, englobando o fim do expediente de trabalho, a saída de estudantes e o deslocamento para atividades de lazer e retorno às residências.




Figura 3. Mapa de calor do dataset teste_agg

A Figura 4 indica a variação do erro absoluto médio em relação às horas do dia. É possível observar que a média do erro sobe conforme o volume de corridas aumenta. Durante a madrugada e o início da manhã, onde a demanda absoluta é estruturalmente menor, o MAE se mantém em patamares baixos, abaixo de 7,5 viagens. Contudo, durante o horário de pico, o erro absoluto médio atinge seus valores máximos, superando a marca de 17,5 viagens em alguns momentos.




Figura 4. Erro absoluto médio por hora do dia

Analisando a Figura 5 observa-se que agregar informações meteorológicas foi de

grande valia, pois variáveis como temperatura, umidade e velocidade do vento possuem grande peso na predição. A variável `hora_do_dia` destacou-se com o maior score.

Em segundo e terceiro lugares encontram-se, a `temperatura` e o `mes`. A alta relevância da `temperatura` indica que o conforto térmico é um fator decisivo para o usuário optar por um táxi em detrimento de uma caminhada ou espera em pontos de ônibus descobertos. O `mes` atua como indicador de sazonalidade anual, capturando mudanças de rotina ligadas às estações do ano e períodos de férias escolares.

De forma contraintuitiva, variáveis que poderiam ser determinantes apresentaram scores baixos. A `precipitacao` obteve o menor score de importância. Isso pode ocorrer devido ao fato de que as chuvas horárias podem ter um comportamento esparso ou porque outras variáveis agregadas como umidade e vento acabaram roubando a variância que a chuva aplicaria no modelo.




Figura 5. Importância das variáveis

O gráfico de dispersão da predição indicado pela Figura 6, demonstra um comportamento que acompanha a linha da predição ideal, mas possui dispersão.




Figura 6. Dispersão da predição

Como já observado na Tabela 2, R^2 ficou em 87,90% e MAE indica que pode existir uma variação de mais ou menos 12,16 corridas em uma hora sobre o resultado do modelo de predição.




Figura 7. Volume de corridas reais e previstas

A Figura 8 possui o comportamento do dataset e da previsão nos primeiros 14 dias de janeiro. Com este recorte, é possível observar as nuances do comportamento de predição. O modelo acompanha com precisão o momento de aumento de demanda, mas encontra dificuldade para prever o comportamento nos momentos de pico.




Figura 8. Comparação de comportamento real e predição em uma janela de 14 dias

7. Limitações ou Ameaças à Validade

Durante o processo de tratamento e unificação dos datasets, foi observada uma redução no volume de dados aplicados ao treinamento do modelo. O dataset inicial de corridas de táxi selecionado para treino possuía 840.402 linhas. No entanto, para que o agrupamento fosse realizado de forma correta com o dataset de clima de treino, que possuía 734.172 linhas, e considerando a eliminação de dados nulos ou discrepantes, o conjunto final de treino resultou em 734.172 linhas. Neste processo, foram retiradas 106.230 linhas do dataset original.

O mesmo comportamento ocorreu na etapa de validação. O dataset de táxi destinado para o teste do modelo possuía originalmente 787.060 linhas, enquanto o dataset de clima de teste possuía 840.402 linhas. Após realizar o tratamento e o agrupamento, o conjunto de dados de teste foi reduzido para 640.265 linhas, de forma que foram retiradas 146.795 linhas do total. Esta perda de dados ocorre pois é necessário manter apenas as informações de corridas que possuem correspondência íntegra entre as viagens e as condições climáticas.

Devido a essa eliminação de dados, constata-se que talvez um volume maior de dados para treino pudesse melhorar os resultados. A inclusão de dados de corridas de anos anteriores para expandir a base de treinamento forneceria ao algoritmo mais exemplos de comportamento, possivelmente auxiliando o modelo de predição a reconhecer com maior precisão os momentos de alta solicitação, diminuindo a dificuldade apresentada para prever o volume nos horários de pico.

A predição foi baseada no cruzamento de informações de corridas de taxi e dados meteorológicos. Uma ameaça à validade deste trabalho é que o comportamento de mobilidade urbana está sujeito a fatores externos não mapeados nos datasets propostos, como a ocorrência de grandes eventos na cidade, acidentes de trânsito ou anomalias no sistema de transporte público.

8. Conclusão

Este trabalho teve como objetivo prever o volume de corridas de Green Taxis na cidade de Nova York utilizando o algoritmo XGBoost associado a dados meteorológicos. A metodologia proposta dividiu o fluxo em duas etapas principais: o tratamento e unificação dos datasets de clima e táxi, utilizando o modelo IterativeImputer para preencher dados faltantes. Para garantir a correta avaliação do modelo, os dados do ano de 2022 foram utilizados para treino, enquanto os dados do ano de 2023 serviram exclusivamente para teste.

Durante o treinamento do modelo de predição, constatou-se que o ajuste empírico dos hiperparâmetros obteve um desempenho superior quando comparado aos métodos de Otimização Bayesiana e GridSearch. O modelo preditivo apresentou 87,90% para o indicador de performance R^2 e Erro Absoluto Médio (MAE) de 12,16 viagens por hora. A análise de importância das features indicou que condições meteorológicas, como a temperatura e a umidade, influenciam a mobilidade urbana. Apesar de o algoritmo acompanhar as tendências diárias de aumento e diminuição do volume de corridas, observou-se que o modelo encontra dificuldade para prever o volume nos momentos de pico, resultando em um erro maior nos horários de maior solicitação de viagens.

Como trabalhos futuros, propõe-se a expansão da base de dados de treinamento, contemplando um volume maior de dados de corridas e clima, para fornecer ao modelo uma maior base de exemplos de alta demanda. Além disso, a adição de novas variáveis, como dados sobre o trânsito local, pode contribuir para mapear as complexidades que fogem do comportamento climático, melhorando a precisão das previsões nos horários de pico.

Referências

Green Cabs (2026). Green cabs vs yellow cabs. <https://greencabs.taxi/>

- green-cabs-vs-yellow-cabs/. Acessado em: 16 jun. 2026.
- Iowa Environmental Mesonet (IEM) (2026). Iowa automated surface observing system (asos) network data archive: New york. https://mesonet.agron.iastate.edu/request/download.phtml?network=NY_ASOS. Acessado em: 14 mai. 2026.
- James, G. (2013). An introduction to statistical learning with applications in python.
- KR, R., S V, S., Jha, T., VS, S., and Rajibul, S. (2024). Dynamic graph convolutional network-based long short-term memory for taxi trip time prediction. In *2024 First International Conference on Software, Systems and Information Technology (SSITCON)*. IEEE.
- New York City Taxi and Limousine Commission (TLC) (2023). 2022 green taxi trip data. https://data.cityofnewyork.us/Transportation/2022-Green-Taxi-Trip-Data/8nfn-ifaj/about_data. Acessado em: 14 mai. 2026.
- New York City Taxi and Limousine Commission (TLC) (2024). 2023 green taxi trip data. https://data.cityofnewyork.us/Transportation/2023-Green-Taxi-Trip-Data/peyi-gg4n/about_data. Acessado em: 14 mai. 2026.
- Poongodi, M., Malviya, M., Kumar, C., Hamdi, M., Vijayakumar, V., Nebhen, J., and Alyamani, H. (2022). New york city taxi trip duration prediction using mlp and xgboost. *International Journal of System Assurance Engineering and Management*, 13(Suppl 1):16–27.
- scikit-learn developers (2026). sklearn.impute.iterativeimputer — scikit-learn documentation. <https://scikit-learn.org/stable/modules/generated/sklearn.impute.IterativeImputer.html>. Acessado em: 16 jun. 2026.
- Uttunga, P. N., Raiker, R. S., Arjun, R., and Tumuluru, V. K. (2025). Spatiotemporal taxi demand prediction with novel clustering and demand disaggregation framework. In *2025 11th International Conference on Communication and Signal Processing (ICCSP)*, pages 1293–1298. IEEE.
- Vanichrujee, U., Horanont, T., Theeramunkong, T., Pattara-atikom, W., and Shinozaki, T. (2017). Taxi demand prediction using ensemble model based on rnns and xgboost. In *IEEE International Conference*. IEEE.
- XGBoost Developers (2026). Xgboost parameters. <https://xgboost.readthedocs.io/en/stable/parameter.html>. Acessado em: 22 mai. 2026.